



MINISTÉRIO DA EDUCAÇÃO
UNIVERSIDADE FEDERAL DE RORAIMA
CENTRO DE CIÊNCIA E TECNOLOGIA
DEPARTAMENTO DE CIÊNCIA DA COMPUTAÇÃO



CLASSIFICAÇÃO DE INSETOS CAUSADORES DE DANOS EM PASTAGEM RORAIMENSE

IBUKUN CHIFE DIDIER ADJITCHE

Boa Vista
Dezembro de 2019

IBUKUN CHIFE DIDIER ADJITCHE

**CLASSIFICAÇÃO DE INSETOS CAUSADORES DE DANOS
EM PASTAGEM RORAIMENSE**

Proposta de Monografia apresentada ao Departamento de Ciência da Computação da Universidade Federal de Roraima como requisito parcial para a obtenção do grau de Bacharel em Ciência da Computação.

ORIENTADOR: DR. LEANDRO NELINHO BALICO

Boa Vista
Dezembro de 2019

Resumo

O ataque de pragas e de doenças é um grande desafio enfrentado por produtores e institutos de pesquisas agropecuárias que buscam qualidade na produção agrícola. Em 2015, no município de Alto Alegre no estado de Roraima, ocorreu o ataque de percevejos de gênero *Blissus pulchellus* e de cigarrinha que teve como impacto a degradação completa das pastagens e um enorme prejuízo econômico para os produtores. A ocorrência desse ataque com o inseto *Blissus pulchellus* foi o primeiro e o único ainda relatado no Brasil. Esse fato despertou o interesse de órgãos de pesquisa como a Embrapa em desenvolver medidas preventivas contra a proliferação do inseto pelo resto do estado e do país, inclusive nas pastagens dos produtores. Um dos passos dessas medidas é a identificação dos insetos, uma tarefa complexa devido à escassez de taxonomistas especializados na região. Entretanto, recentes avanços em áreas como a Aprendizagem de Máquina possibilitam ferramentas de identificação baseadas em imagens digitais, tendo a acurácia assertiva maior que um especialista. Dessa forma, esse trabalho propõe a avaliação de métodos de Aprendizagem de Máquina na classificação de insetos causadores de degradação nas pastagens nos estados de Roraima.

Palavras-Chaves: Pastagem, Insetos-Pragas, Aprendizagem de Máquina, Classificação;

Abstract

The attack of pests and diseases is a major challenge faced by farmers and agricultural research institutes seeking quality in agricultural production. In 2015, in the municipality of Alto Alegre in the state of Roraima, *Blissus pulchellus* and leafhopper bedbugs attacked, which had the impact of complete pasture degradation and an enormous economic loss for producers. The occurrence of this attack with the insect *Blissus pulchellus* was the first and only reported in Brazil. This fact aroused the interest of research agencies such as Embrapa in developing preventive measures against insect proliferation throughout the rest of the state and the country, including on the producers' pastures. One of the steps of these measures is the identification of insects, a complex task due to the scarcity of specialized taxonomists in the region. However, recent advances in areas such as Machine Learning enable digital imaging-based identification tools with assertive accuracy far more advanced than a specialist. Thus, this work proposes the evaluation of Machine Learning methods in the classification of degrading insects in pastures in the states of Roraima.

Keywords: Grassland, Pest Insects, Machine Learning, Classification;

Lista de Figuras

1.1	Inseto-Pragas e Degradação: (a) <i>Blissus pulchellus</i> ; (b) Pastagem em Degradação; e (c) Ninfas de inseto.	2
3.1	Método Proposto	11
3.2	Característica e Algoritmo de Extração (Kalafi et al., 2018)	15
4.1	Ferramenta de Aquisição: (a) Caixa ligada aberta ; (b) Caixa ligada e fechada; (c) Ambiente da caixa; (d) Lupa eletrônica.	19
4.2	Ilustrando a Matriz de Confusão (Géron, 2017)	21

Lista de Tabelas

3.1	Classificadores Recorrentes (Martineau et al., 2017)	17
5.1	Cronograma das Atividades.	23

Sumário

Resumo	iii
Abstract	iv
Lista de Figuras	v
Lista de Tabelas	vi
1 Introdução	1
1.1 Objetivos	4
1.2 Organização do Trabalho	4
2 Trabalhos Correlatos	5
3 Fundamentação Teórica	9
3.1 Introdução	9
3.2 Método Proposto	10
3.3 Aquisição de Imagem	11
3.4 Pré-processamento de Imagem	12
3.5 Segmentação de Imagem	13
3.6 Extração de Característica na Imagem	14
3.7 Classificação da Imagem	16
4 Metodologia Proposta	18
4.1 Ambiente da Experiência	18
4.2 Coleta de Dados	19
4.3 Métricas de Desempenho	20
4.4 Parâmetros Experimentais	21
5 Cronograma	23
Referências Bibliográficas	24

Capítulo 1

Introdução

A produção Agropecuária, em certos países do mundo apresenta um grande impacto econômico. Assim vários recursos financeiros e operacionais são implementados para garantir a qualidade de produção e enfrentar degradações dos cultivos (Picon et al., 2018). Na região Amazônia brasileira, as pastagens sendo as principais fonte alimentares no rebanho (Jonas, 1986; Dias, 2011; Bendahan, 2015), apresentam em grande parte, algum grau, de degradação (Dias, 2011; Bendahan, 2015). Diversos fatores contribuem para essa degradação, entre eles podemos citar: pragas e doenças de forrageiras, drenagem deficiente dos solos; excesso ou falta de chuvas; baixa fertilidade do solo; má-formação inicial das pastagens; e sobretudo, o manejo inadequado das pastagens (Jonas, 1986; Bendahan & da Veiga, 2000; Andrade & Valentim, 2006; Dias-Filho, 2007).

Depois do manejo das pastagens, o principal fator que contribui com essa degradação na região, são os ataques de insetos-pragas (terminologia científica de insetos causadores de danos), sobretudo, os de cigarrinhas e lagartas das pastagens (César et al., 2019) (Figura 1.1(c)). De acordo com Huddar et al. (2012) importante parte da produção agrícola é perdida a cada ano, devido à infestação dos insetos. Dessa forma, com a paulatina degradação do ecossistema forrageiro, os produtores tendem a avançar no desmatamento de novas áreas, pois com a queda na produção de forragem, é necessário o aumento de áreas para suprir a demanda causada pela degradação (Jonas, 1986; Andrade & Valentim, 2006; Dias-Filho, 2007).

Recentemente no Estado de Roraima, ocorreu o ataque severo de insetos-pragas, particularmente do percevejo do gênero *Blissus pulchellus* (Teixeira, 2016; Da Silva, 2019) (Figura 1.1(c)). O inseto tem sido observado em pastagens de *Urochloa brizantha* (1.800 percevejos/m²) e em *Panicum maximum* cv. Mombaça (800 percevejos/m²), especialmente no município de Alto Alegre (Simon et al., 2017), e a sua densidade populacional, tem sido maior do que observada em outras regiões do Brasil, em comparação às espécies *Blissus leucopterus* e *Blissus antillus*. Assim, vale ressaltar que a

ocorrência desse ataque da espécie *Blissus pulchellus*, foi o único e o primeiro relatado no Brasil.

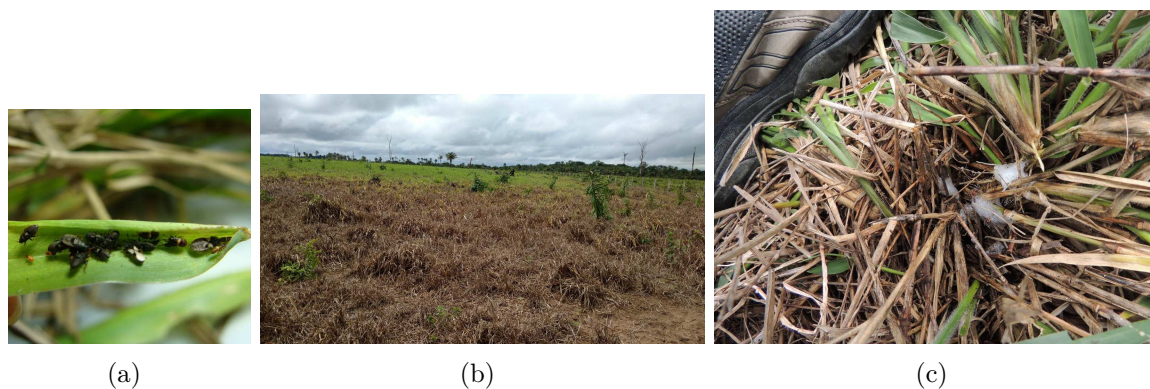


Figura 1.1. Inseto-Pragas e Degradação: (a) *Blissus pulchellus*; (b) Pastagem em Degradação; e (c) Ninfas de inseto.

Nesse contexto, o manejo de pragas tem ganhado importância nas agendas de técnicos e produtores. Se, no passado, os efeitos desses organismos eram menos notados, atualmente com a intensificação da produção pecuária, ficaram mais visíveis. Convencionalmente, as técnicas de monitoramento e detecção de pragas em fazendas são feitas pelos dispositivos de armadilhas adesivas (Choi et al., 2007), e de armadilhas de luz negra (Mutwiwa & Tantau, 2005). Mas, essas técnicas manuais se mostraram extremamente demoradas e subjetivas à disponibilidade de um especialista humano para detectar o mesmo (Martin et al., 2008).

Anteriormente segundo Zhang (2011) a identificação de insetos é difícil devido à sua imensa diversidade de espécies e a variação significativa em relação ao sexo, as mudanças de cor e o estágio de vida. Com algum treinamento, pode-se aprender como distinguir grupos taxonômicos mais altos, como ordens, mas já no nível familiar, a tarefa se torna bastante desafiadora, mesmo para especialistas, a menos que restrinja-se o problema a um estágio específicos da vida, região geográfica ou ordem de insetos.

Por essas razões, vários pesquisadores há muito tempo se interessam em desenvolver sistemas automatizados baseados em imagens na identificação de insetos (Schröder et al., 1995; Weeks et al., 1997, 1999b,a; Gauld et al., 2000; Arbuckle et al., 2001; Watson et al., 2004; Tofilski, 2004, 2007; O'Neill, 2000; Steinhage et al., 2007; Franco et al., 2008; Yang et al., 2015; Feng et al., 2016; Martineau et al., 2017). O ponto comum de todos sistemas projetados até os dias de hoje foi baseado na extração de recursos artesanais, denominados "*Handcrafted*" ou "*Handengineered*", terminologia que designa os padrões de aprendizagem de máquina e de visão computacional,

referentes à aplicação de algum processo, como um algoritmo ou um procedimento manual, para extrair recursos relevantes na identificação dos dados brutos (imagens neste caso).

Como exemplo de características na identificação taxonômica, pode-se citar: o padrão de venação da asa, a posição relativa das junções das veias da asa e o contorno da asa ou de todo o corpo. Embora muitos desses sistemas alcancem um bom desempenho de identificação, a necessidade de extração de recursos especiais personalizados para cada tarefa limitou seu uso na prática.

O poder computacional que as unidades de processamento gráfico trazem, hoje em dia, desencadeou uma série de abordagens eficientes em problemas de classificação automatizada e possibilitaram um impacto transformador no campo da visão computacional e dos algoritmos de aprendizagem de máquina (LeCun et al., 2015; Schmidhuber, 2015). Deste modo, os algoritmos de reconhecimento de padrões automatizados têm aumentado a possibilidade de extrair e analisar características informativas de espécies em imagens digitais (Kalafi et al., 2018). O que alavancou em pesquisas de automação, a exploração de horizontes, que se mostraram limitado para os taxonomistas usando os métodos tradicionais de automação pré-existente.

Segundo Elsayed et al. (2018), os algoritmos de machine learning foram usados até em agricultura para detectar, quantificar, prever, identificar e classificar precocemente doenças de plantas, bem como a identificação de espécies de plantas ou grupo de espécies com base em suas características como tamanho, forma, cor, textura, veias das folhas, ramificação, sementes e mudas de plantas.

Essas circunstâncias atuais, levam nestes trabalhos a exploração das possibilidades de fazer uso dos mesmos algoritmos no reconhecimento por classificação de pragas-insetos que atacam as pastagens forrageiras na região da Amazônia mais precisamente no estado de Roraima. Pois atualmente, existem controvérsias sobre a identificação de algumas espécies do gênero *Blissus*, as principais envolvem as espécies *Blissus leucopterus* (Say) e *Blissus antillus* no Brasil, (VALERIO et al., 2015) remetendo a sociedade científica à necessidade de revisão taxonômica apoiada por técnicas moleculares.

Diante desta situação, é necessário portanto, tomar medidas preventivas, seja para erradicar os insetos ou controlar seus efeitos nocivos nas pastagens. Porém, essas medidas serão agilizadas na medida em que as técnicas de identificação se tornarão mais eficientes e robustas. Neste contexto a problemática destes trabalhos venha se focar sobre a necessidade de proporcionar uma ferramenta que possa ajudar os produtores ou os especialistas na identificação rápida destas pragas para que possa se tomar

decisão de controle e não deixar as pastagens degradar, causando danos econômicas até prejudicando a segurança alimentar.

1.1 Objetivos

O objetivo principal desse trabalho é avaliar métodos de aprendizagem de máquina na classificação de insetos causadores de degradação nas pastagens no estado de Roraima.

Os objetivos específicos são:

- Analisar e avaliar padrões de aquisição, processamento e segmentação de imagem digitais.
- Criar e avaliar uma base de dados para o reconhecimento de insetos pela classificação.
- Analisar e avaliar técnicas ou algoritmos de classificação de insetos-pragas.

1.2 Organização do Trabalho

A organização deste trabalho está organizada em 4 capítulos. A **Introdução**, no capítulo 1, apresentando a contextualização do trabalho bem como seus objetivos e a definição do problema. Os **Trabalhos Correlatos**, no capítulo 2, apresentam trabalhos focados identificação e classificação de inseto a por meio de imagens digitais usando aprendizagem de máquina. A **Fundamentação Teórica** é apresentado no capítulo 3, enumerando os contextos e definições das etapas dos métodos a serem avaliados. No capítulo 4, a **Metodologia Proposta** no trabalho é explicada, com as ferramentas que serão utilizadas. O **Cronograma** das atividades para o cumprimento deste trabalho é mostrado no capítulo 5.

Capítulo 2

Trabalhos Correlatos

Na literatura, há vários trabalhos relacionados a aplicação da aprendizagem de máquina na agricultura. Aquele que tem como fonte de dados as imagens digitais passam necessariamente pelas etapas básicas de coleta de dados, processamento, extração e classificação. A seguir serão relatados os principais trabalhos que serviram de motivação para o estudo sobre a identificação de inseto-praga, com foco nos algoritmos usados para classificação.

No trabalho de [Wang et al. \(2012\)](#), um novo sistema de identificação pela ordem de inseto foi apresentado para atender a necessidades públicas de identificar na prática, imagens de insetos. Foram coletado 225 imagens de amostra de nove ordens ou subordinados, ou seja, 25 imagens de cada ordem e as amostras incompletas foram removidas por meios do processamento manual. Além do processamento manual, um método automático de processamento foi usado nesse trabalho para obter uma imagem normalizada cujo fundo é definido com uma cor pura que não aparece na amostra de inseto. A ferramenta BugVisux foi usada para extrair chaves ou recursos taxonômicos como: o tamanho do corpo do inseto, o centro de gravidade (P), o tamanho da parte superior a partir do centro de gravidade, a proporção da área corporal (BAR), a excentricidade corporal (BE), a razão de comprimento da parte superior do corpo (ULR), a relação da largura (WR), a proporção da área da parte superior do corpo (UAR), o parâmetro da forma do corpo (BSP) e a complexidade da cor (CC).

Ainda, segundo [Wang et al. \(2012\)](#), esses recursos são extraídos a priori automaticamente, mas como os resultados de extração de recurso são pouco afetados pela qualidade da imagem, foi proposta nesse trabalho uma interface de usuários que possa corrigir manualmente os erros na variáveis-chave no método automatizado. Uma rede neural artificial supervisionada de retro-propagação de três camadas (entrada, oculta e saída) foi usada para treinar as chaves tendo como métrica os parâmetros importantes

como: α , *momentum* e a taxa de aprendizado. O classificador de vetores de suporte C da SVM com a função *Radial base Kernel* (RBF) foi também usado como classificador das chaves taxonômicas. Como resultado Wang et al. (2012) observaram que a precisão média dos testes em diferentes divisões do conjunto de imagens foi 67%. A partir disso ele afirma que a divisão do conjunto de imagens de treinamento tem pouca influência no resultado do teste, e é melhor focar em outros aspectos, como a eficiência dos recursos abstraídos. No que diz respeito aos algoritmos, ele afirma que ambos produzem resultados razoavelmente bons em testes com sete recursos, e o desempenho da SVM supera a RNA apesar da otimização dos hyper-parâmetros.

Os mesmos algoritmos foram usados pelo Bisgin et al. (2018) na busca de identificar as espécies de besouros. Mas antes, 15 espécies diferentes de besouros e seus élitros foram cuidadosamente fotografados e as imagens coletadas foram aprimoradas através de filtros gaussianos e a equalização de histograma. Todos os recursos das imagens foram categorizados em 3 conjuntos a saber: Recursos Global 1 (GF1), Recurso Global 2 (GF2) e Recurso Local (LF). As características gerais como tamanho, cor, padrão básico e texturas foram categorizadas como GF1 e características mais detalhadas, como tipo de padrão (pêlos, cordilheiras, bosque e protuberâncias) e sua periodicidade foram categorizadas como GF2. Os detalhes microscópios adicionais como pequenas alterações dentro e ao redor de cada ponto do padrão foram categorizados como LF.

Antes de proceder a classificação dos recursos, nesse trabalho também foi proposto um método visando minimizar a redundância, selecionou característica que apresenta uma representativa melhor associada a identificação da espécie. Assim foi escolhido aleatoriamente 80% das amostras para construir o classificador e 20% na validação cruzada. Os Dados foram treinados com os algoritmos *Scaled Conjugate Gradient* (SCG) e *Resilient Backpropagation* (RP) da rede neural artificial e otimizado para 1, 2, 3 camadas ocultas. Além disso o número dos nós foi aumentado e foram executadas as funções *Traincg* e *Trainrp* no *MATLAB*, fornecendo 36 arquiteturas diferentes de RNA. Os mesmos dados foram treinados com a SVM usando o *LIBSVM* e a função *Radial Base Kernel* (RBF). Quanto ao procedimento de otimização foi buscado o melhor parâmetro γ para a função RBF junto com o melhor parâmetro de regularização C. Como resultados, Bisgin et al. (2018) afirmaram que o SVM teve uma precisão média de 85%, ao contrário da RNA, de 80% de precisão após extensa otimização de parâmetros. Como conclusão, ele afirma que a identificação altamente precisa do nível de espécie continua sendo um desafio, especialmente na distinção entre espécies do mesmo gênero, o que pode exigir melhorias nas técnicas de imagem e aprendizado de máquina.

Visto que nos trabalhos de Wang et al. (2012) e de Bisgin et al. (2018), as chaves taxonômicas foram decisivas para o sucesso das classificações, e de um jeito para outro exigem conhecimentos técnicos taxonômicos a respeito dos insetos, Valan et al. (2019) apresentou no seu artigo, uma das primeiras aplicações de transferência de recursos da CNN para tarefas taxonômicas desafiadoras e realistas, onde é esperado um alto nível de precisão na identificação. Dois tipos de tarefas taxonômicas desafiadoras foram abordadas, são: a identificação de grupos superiores em que provavelmente muitos espécimes pertençam a um subgrupo que não foram vistos anteriormente, e identificação de espécies visualmente semelhantes que são difíceis de separar para especialistas. Na primeira tarefa foram reunidos dois conjuntos de dados que consistem em diversas imagens de faces de *Diptera* e *Dorsal habitus Coleoptera*. E na segunda tarefa, imagens de três espécies estreitamente relacionadas de gênero *Coleoptera oxythyrea* e de nove espécies de larvas *Plecoptera*.

A arquitetura CNN VGG16 com pesos pré-treinados no conjunto de dados ImageNet (Simonyan & Zisserman, 2014) foi usado como extrator de recursos e um SVM linear (Cortes & Vapnik, 1995) na classificação das imagens. Como resultados, segundo Valan et al. (2019), a abordagem da primeira tarefa alcançou mais de 92% de precisão em um conjunto de dados (884 imagens de face de 11 famílias de *Diptera*) e mais de 96% de precisão em outros (2936 imagens de *Dorsal Habitus* de 14 famílias de *Coleoptera*). Na segunda tarefa, a abordagem superou um especialista taxonômico líder em um conjunto de dados (339 imagens de três espécies de gênero *Coleoptera oxythyrea*; precisão de 97%), e humanos e sistemas de identificação automatizados tradicionais em outro conjunto de dados (3845 imagens de nove espécies de larvas *Plecoptera*: precisão de 98,6%). Para concluir, Valan et al. (2019), afirmaram que o método pode ser altamente bem-sucedido no desenvolvimento de sistemas automatizados de identificação taxonômica, mesmo quando os conjuntos de dados de treinamento são pequenos e os orçamentos computacionais limitados.

Em geral, os trabalhos relacionados apontam vários desafios no que diz respeito a forma de extrair as chaves taxonômicas ou recursos representativos da espécie em identificação, quando a mesma espécie apresenta várias semelhanças com outras espécies do mesmo gênero. O algoritmo de classificação privilegiado para essas tarefas em ênfase foi a SVM, superando o algoritmo de rede neurais artificial. E também vale ressaltar que o processamento e a extração dos dados estão intimamente relacionados a natureza das espécies a identificar, nos trabalhos de Wang et al. (2012) e Bisgin et al. (2018), quanto a Valan et al. (2019), a CNN com pesos pré-treinado funciona como uma caixa preta e faz automaticamente o processamento e a extração. Assim os métodos de

processamento de imagens e de extração de característica se mostraram de uma suma importância, como fatores capazes de impactar no desempenho do treinamento dos classificadores.

Entretanto, nenhuma pesquisa foi feita usando outros algoritmos como KNN, Random Forest e XGboost que hoje em dia foram bastante melhorados e apresentam também bom desempenho nas tarefas de classificação. Inclusive, nenhuma literatura até então se refere a classificação automática de perceijos de gênero Blissus e uma quase inexistência de banco de dados disponíveis para que possamos usar a aprendizagem de máquina profundo que atualmente apresenta um desempenho perfeito com um orçamento realista para produtores e pesquisadores. Por isso, esse trabalho, focará na avaliação de método de classificação usando os algoritmos de SVM, KNN, Random Forest e XGboost. Nos próximos capítulos as etapas do método escolhido será explicado junto com a metodologia proposta.

Capítulo 3

Fundamentação Teórica

Este capítulo é organizado da seguinte forma. A seção 3.1 introduz o contexto da evolução das pesquisas de identificação de insetos. A seção 3.2 descreve brevemente o método proposto em relação a o que está feita na literatura. E o restante das seções 3.3, 3.4, 3.5, 3.6 e 3.7 descrevem, respetivamente, o que são feitas em cada etapas do método proposto.

3.1 Introdução

Os insetos, sendo da classe invertebrado e parte dos artrópodes, representam segundo [Ødegaard \(2000\)](#) até 80% do filo animal e a maior proporção de riqueza de espécies em qualquer escala espacial ([Hammond, 1992](#)). Apesar de serem indicadores eficiente das funções e impactos de ecossistemas causados pela atividade humana ([Kremen, 1992](#); [Kimberling et al., 2001](#); [Lawton et al., 1998](#); [Andersen, 1990](#)), a identificação das espécies está retardada pelo alto nível de conhecimento necessário.

Tradicionalmente, Segundo [Martineau et al. \(2017\)](#), a identificação tem sido baseada em diagnósticos morfológicos fornecidos por estudos taxonômicos. Somente especialistas como taxonomistas e técnicos treinados podem identificar com precisão, porque exige habilidades especiais adquiridas por meio de uma vasta experiência. No entanto, o número de taxonomistas e outros especialistas em identificação diminuiu drasticamente. Em alguns casos, um técnico treinado pode fazer identificações de rotina usando *chaves* morfológicas (instruções passo a passo do que procurar), mas na maioria dos casos é necessário um taxonomista profissional experiente. Consequentemente, são necessários métodos de identificação alternativos e precisos que também não-especialistas possam usar. Assim sendo, pesquisas sobre sistema automatizado de reconhecimento de insetos via imagens digitais vem sendo desenvolvidas. Algumas das ferramentas criadas, são:

- ABIS: especializada na identificação de abelhas pelas veias das asas ([Schröder et al., 1995](#));
- DAISY: sistema de identificação de imagens digital baseada na identificação de impressões digitais ([O'Neill et al., 2000](#); [Watson et al., 2004](#); [Weeks et al., 1997](#));
- BugVisux: especializada na identificação usando a características morfológicas ([Hanqing et al., 2002](#));
- But2Fly: especializada na identificação de espécies de borboletas através das características de cores das asas ([Liu et al., 2008](#));

3.2 Método Proposto

Segundo [Wang et al. \(2012\)](#), embora os sistemas acima mencionados se concentrem na identificação de insetos no nível das espécies, a identificação automática de insetos no nível da ordem também é importante, especialmente na ciência popular e na identificação inicial de insetos. Ainda segundo ele, um espécime, geralmente, precisa ser identificado no nível da ordem ou no nível da família antes que um nome seja atribuído pelos taxonomistas. Assim a identificação será mais útil para os taxonomistas públicos e juniores. Portanto, poucas pesquisas foram realizadas a respeito da identificação pela ordem, por causa das inúmeras espécies e aos complexos sistemas de classificação de insetos. A título de exemplo, o autor afirma que dentro de cada ordem as espécies podem ser altamente diferentes umas das outras, especialmente no nível da família, enquanto algumas espécies em ordens diferentes podem parecer semelhantes. Isso dificulta a formulação matemática de descrições taxonômicas de ordem, a ser entendido pelo computador.

Assim o trabalho de [Wang et al. \(2012\)](#) apresentou novo, um sistema de identificação projetado da seguinte forma: a coleta de imagem de várias espécies, implementação de uma solução de pré-processamento das imagens, extração de recursos taxonômicas, e o uso de algoritmos de reconhecimento de padrão. Nosso método proposto seguirá também as etapas projetadas do [Wang et al. \(2012\)](#), que geralmente são um roteiro bem conhecido nas tarefas de classificação, tendo como base de dados, as imagens digitais. Será observado uma combinação de vários testes na aquisição, no processamento e na segmentação de imagens nesse trabalho afim de adaptar um padrão de qualidade adequada para a eficiência da extração de características. No que diz respeito a extração, a Cor, a Textura e a Morfologia serão consideradas e testadas como entrada

aos algoritmos de aprendizagem de máquina. Essa abordagem é relativamente adaptada devido, primeiro à perplexidade da quantidade de imagem que poderia se obter na aquisição, segundo da eficiência que poderemos abstrair dos algoritmos se for bem calibrado e terceiro aos resultados e análise que poderia ser útil para bem entender a base de dados e o desafio que estamos a resolver. A seguinte figura 3.1 esquematiza o trabalho que será realizado.

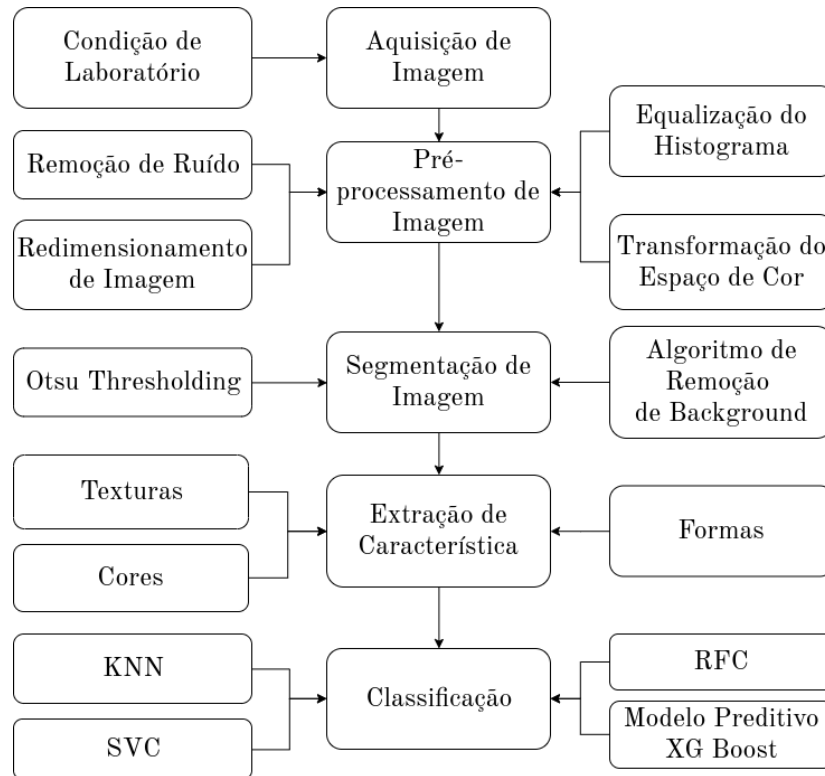


Figura 3.1. Método Proposto

Nas próximas seções, serão apresentados os fundamentos descrevendo cada etapa do método proposto que são a aquisição, pré-processamento, segmentação, extração das características da imagem e em fim, a classificação propriamente dita.

3.3 Aquisição de Imagem

De fato, o modo de aquisição pode influenciar as técnicas utilizadas para a identificação dos insetos, mas também o contexto de aplicação de tais algoritmos (Martineau et al., 2017). Neste contexto, várias dimensões analíticas podem ser consideradas. A primeira, diz respeito às condições de aquisição, que tratam basicamente dos insetos (tanto na forma como são capturados quanto tratados) e na maneira como

as imagens são produzidas (as ferramentas de capturas e o protocolo geral). A segunda faz alusão a restrição de postura, ou seja, enquanto permitirmos a variação do ângulo do inseto. Por exemplo a captura da parte de frente do inseto pode ser considerada caso isso, é objeto de pesquisa. Uma configuração de pose sem restrição, induz a variabilidade na orientação do inseto e, portanto, em suas formas, detalhes e cores aparente.

De acordo [Martineau et al. \(2017\)](#), o local de captura do inseto é intimamente relacionado à restrição de postura. Este local pode ser um ambiente de laboratório ou de campo. Os ambientes de laboratório são geralmente usados pelos entomologistas, onde o inseto é identificado e inspecionado. Portanto, os entomologistas têm a possibilidade de gerenciar o sistema de aquisição de imagens. A aquisição baseada em campo como o próprio nome já define, as imagens são capturadas diretamente em campo de cultivos, sem qualquer restrições específicas. Isso estipula que normalmente, a aquisição é feita por um dispositivo móvel e o inseto está vivo quando a foto é tirada. O contexto de aplicação desse tipo de cenário é o de um agricultor que deseja identificar um inseto para saber, por exemplo, se ele pertence a uma espécie devastadora ou não.

3.4 Pré-processamento de Imagem

O objetivo do processamento de imagens é transformar imagens digitais em uma pose padrão ([Gonzalez RC, 2007](#)) e alcançar objetos reconhecíveis em um fundo uniforme. Para facilitar a etapa de segmentação, os artefatos da imagem devem ser removidos, também o contraste e a faixa dinâmica precisam ser melhorados. O aprimoramento da imagem pode ser realizado por métodos manuais ou automáticos. Métodos manuais, como os realizados usando ImageJ ([Kiranyaz et al., 2011](#); [Mayo & Watson, 2007](#)) ou Photoshop ([Larios et al., 2008](#)), podem produzir melhores resultados de pré-processamento de imagem. No que diz respeito para sistema de grande número de imagens é aconselhável usar métodos totalmente automatizados, pois processamento manual de imagens exigem um tempo mais longo.

Imagens digitais de espécies, especialmente imagens microscópicas, geralmente contêm poeira ou outros artefatos de ruído. O ruído faz com que os valores dos pixels vizinhos sejam confusos ([Trattner et al., 2004](#)), portanto deve ser reduzido pelos métodos de filtragem suavizados. É importante conhecer os tipos predominantes de ruído a ser filtrado para que possa ser removido com mais eficiência. Amplificador ou gaussiano, sal e pimenta, grão de filme, não isotrópico, manchas e ruído periódico são os tipos

mais comuns de ruído. Os filtros de redução de ruído podem ser divididos em duas categorias: filtros lineares e filtros não lineares (Mythili & Kavitha, 2011). A filtragem mediana (Bovik et al., 1987) é uma filtragem não linear que é comumente aplicada à imagem microscópica digital (Avcı & Varol, 2009; Hernández-Serna & Jiménez-Segura, 2014; Saraswat & Arya, 2014; Yang et al., 2008). Leow et al. (2015) aplicaram filtragem mediana com núcleo 10x10 em sistema de identificação automatizada de copépodes para suprimir o ruído de sal e pimenta criado na água nas imagens.

A qualidade da imagem é altamente afetada pela iluminação, contraste, foco e resolução de aquisição (Castañón et al., 2007). De acordo com Arce et al. (2013); Bradbury MH (1998); Saraswat & Arya (2014), essas variações na iluminação podem ser causadas por diferentes tipos de lentes e fontes de luz. Segundo Castañón et al. (2007), o uso da equalização do histograma pode ser aplicada para reduzir a variação na iluminação, sendo por exemplo aumentando o contraste esticando o histograma da imagem digital, o que espalhará os valores de pixel mais brilhantes e mais escuros nos níveis de cinza e depois, a atribuição de branco e preto.

3.5 Segmentação de Imagem

Um dos estágios fundamentais antes da extração e classificação dos recursos é a segmentação (Haralick RM, 1992). A segmentação separa o plano de fundo do primeiro plano e é importante na visão computacional, que encontra a localização dos pixels identificando um objeto. Os pixels com características comuns são agrupados de acordo com os algoritmos de segmentação. Segundo Culverhouse et al. (1996), embora que existem algoritmos de segmentação automatizada que possuem imperfeições, existem sistemas automatizados robustos que podem categorizar as espécies satisfatoriamente. A segmentação por parte de imagem de objeto de interesse geral é mais eficaz ao usar informações limitante mostrando a forma que se deseja extrair ou reconhecer. O algoritmo de Grabut (Rother et al., 2004), neste sentido mostrou a sua eficiência, na remoção de *background* na identificação automatizada de espécies (Leow et al., 2015), pela otimização iterativa de corte de gráfico, combinada com a borda fosca para eliminar os pixels mistos e desfocados nos limites do objeto.

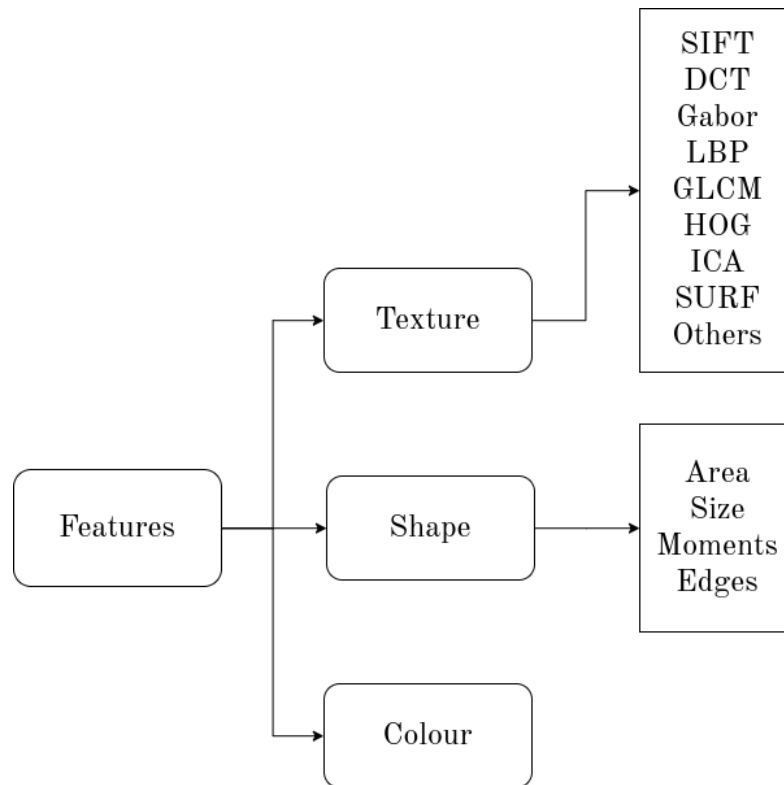
Uma outra técnica de segmentação é a *Deteção de Borda* (Gonzalez RC, 2007), que pode ser alcançada por filtros como o Canny (Canny, 1986) ou o Sobel (Gonzalez RC, 2007), e foi aplicada no sistema de identificação automática de algas (Santhi et al., 2013), devido as bordas e contornos significativos. É também usado a técnica *Limiar*

que consista a produzir imagens binárias de acordo com o valor de corte. Este método pode ser subclassificado principalmente para técnicas de limiares dinâmicas, globais e locais (Kang et al., 2009; Singh et al., 2012). De acordo com Martineau et al. (2017), a maneira mais simples de fazer limiar é definir o valor da intensidade que separa os dois grupos. Este valor pode ser definido estaticamente no programa pelo usuário que pode selecionar o que produz o melhor resultado, como em (Dietrich et al., 1991; Dietrich & Pooley, 1994). Outra maneira de executar o limiar é vê-lo como um problema de agrupamento em que dois ou mais clusters (que são as regiões) precisam ser formados (Faithpraise et al., 2013; Wen & Guyer, 2012; Solis-Sánchez et al., 2009; Zhu & Zhang, 2010, 2011; Mayo & Watson, 2007). Por exemplo, o critério do método de Otsu funciona sobre a escolha dos clusters, de modo que a variação intra-cluster seja minimizada enquanto a inter-cluster é maximizada (Solis-Sánchez et al., 2009; Zhu & Zhang, 2010, 2011), por outro lado, o k-means faz uso do espaço de cores para procurar centróides representando as diferentes regiões da imagem com base na semelhança de cores (Wen & Guyer, 2012; Faithpraise et al., 2013). Sobre os métodos de segmentação, em geral, na literatura seis métodos têm destaque: Thresholding (Gonzalez RC, 2007), método baseado na teoria fuzzy, método baseado em equações diferenciais parciais, método baseado em redes neurais artificiais, método baseado em regiões e baseadas em bordas (Kang et al., 2009; Khan, 2013).

3.6 Extração de Característica na Imagem

Os tipos de recursos mais destacados em imagens são: as formas, cores e texturas (Islam et al., 2008; Ping Tian et al., 2013; Shih et al., 2001). A figura 3.2 (Kalafi et al., 2018), ressalta essas características e inclusive aponta alguns algoritmos relacionados a elas. De acordo com (Kalafi et al., 2018), a extração de recursos em sistemas automatizados pode depender do nível de identificação, o que significa que os recursos para detecção no nível da ordem são diferentes daqueles no nível da espécie. Por exemplo, no sistema automático de identificação de moscas-brancas, pulgões e tripes, fatores como tamanho, forma do contornos e componentes de cores foram considerados (Cho et al., 2008), devido às diferentes partes anexadas de cada inseto, o limite morfológico não foi utilizado e apenas três componentes e tamanho de cores foram aplicados como recurso. No que diz respeito a identificação automática de espécies de borboletas, Kaya et al. (2015) extraíram cinco características de textura: média, correlação, entropia e energia da matriz LBP. Os padrões binários locais (LBP) (Ojala et al., 2002) são considerados como descritores de textura e são aplicados na análise de imagens. No seu trabalho, Hernández-Serna & Jiménez-Segura (2014) propuseram um sistema automatizado

aplicável à identificação e classificação de plantas, peixes e borboletas. Sua abordagem neste sistema se estendeu a três grupos taxonômicos diferentes, portanto, a extração de características deve ser o mais geral possível, da maneira que pode ser aplicada a todas as espécies. Eles usaram área, perímetro, diâmetro, compatibilidade, compacidade e solidez como características geométricas, uniformidade, mediana, entropia, variação, inércia, homogeneidade e co-ocorrência como características de textura e [Hu \(1962\)](#) e [Flusser & Suk \(1993\)](#) como características morfológicas.



Content-based features; SIFT — scale-invariant feature transform; DCT — discrete cosine transform; LBP — local binary patterns; GLCM — grey-level co-occurrence matrix; HOG — histogram of oriented gradient; ICA — independent component analysis; SURF — speeded-up robust features.

Figura 3.2. Característica e Algoritmo de Extração ([Kalafi et al., 2018](#))

Nos últimos anos, uma grande quantidade de pesquisas sobre reconhecimento visual se concentrou no aprendizado de recursos de nível baixo e médio, usando a aprendizagem não-supervisionada, aprendizagem supervisionada ou uma combinação de ambas.

De acordo com [Martineau et al. \(2017\)](#), capacidade da aprendizagem em vários níveis de boas representações de recursos em uma estrutura hierárquica ajuda a construir sistemas sofisticados de reconhecimento. Em ([Wen et al., 2015](#)), séries de características geométricas, de forma, momento invariante, textura e cor são fornecidas como entrada para um *Autoencoder Stacked Denoising*. Essa arquitetura de *Deep Learning* se consistia em vários níveis de operações não-lineares e é uma maneira eficaz de representar abstrações de alto nível. O aprendizado automático de recursos em vários níveis de abstração permite que um sistema de aprendizado profundo aprenda funções complexas, mapeando a entrada para a saída diretamente dos dados ([Bengio et al., 2009](#)).

3.7 Classificação da Imagem

A ideia da classificação é classificar objetos de interesse com base em um conjunto de dados de recursos específicos para discriminar classes distintas. O desempenho dos classificadores é altamente afetado pelo processo de segmentação e extração de recursos. No seu artigo, [Jain et al. \(2000\)](#) propuseram três categorias de classificadores: baseado em similaridade, probabilístico e limites de decisão. Reiterando a ideia de [Jain et al. \(2000\)](#), [Martineau et al. \(2017\)](#) categoriza melhor os métodos de classificação (Tabela 3.1) da seguinte forma:

1. Classificadores monolíticos

Existem duas maneiras de ver a classificação conceitualmente:

- de maneira discriminatória que tende a estabelecer limites em um determinado espaço de recurso entre as diferentes populações, a fim de distingui-las. Isto é, estocasticamente falando, modelar $P(C = c/X)$, ou seja, probabilidade de ocorrência da classe c dada x (vetor de características);
- e generativa que está tentando estimar a probabilidade de um indivíduo pertencer a uma determinada população. Para continuar usando o ponto de vista probabilístico, as abordagens generativas estão modelando $P(X/C = c)$, ou seja, a probabilidade de ocorrência do vetor de característica x se considerar a classe c .

2. Combinações

Quando se trata de questões como super adaptação, um classificador monolítico não é suficiente e é aqui que a aprendizagem por conjuntos é relevante. A ideia do aprendizado de conjunto (combinação) é usar uma combinação dos referidos

classificadores fracos para obter um classificador forte (Rokach, 2010). As combinações de classificadores também visam melhorar o desempenho de classificadores simples.

3. Baseado em instância

Esse método lida com o problema de classificação comparando imagens desconhecida não com as próprias classes, mas com ocorrências conhecidas (que acabam sendo as imagens de aprendizagem).

A maioria dos métodos de classificação é mencionada em (Loncaric, 1998; Savkare et al., 2011; Zhang & Lu, 2004), incluindo métodos estruturais, difusos, de transformação, baseados em redes neurais e entre outros. Alguns sistemas de identificação automatizada (Leow et al., 2015) empregam redes neurais ou algoritmos de aprendizado quando existem muitas classes e um pequeno número de amostras, mas alguns outros sistemas (Parisi-Baradad et al., 2010) que lidam com um grande número de amostras usam preferencialmente outros algoritmos como o KNN (Duda et al., 2012).

Category Levels		
Monolithic	Discriminative	Linear SVM Neural nets Decision trees
	Generative	Parametric Density estimation Other
Combinations	Committees Boosting and bagging Other	
Instance-based	K-NN Other	

Tabela 3.1. Classificadores Recorrentes (Martineau et al., 2017)

No próximo capítulo, será discutido a metodologia proposta para a classificação dos insetos-pragas.

Capítulo 4

Métodologia Proposta

4.1 Ambiente da Experiência

A fase de aquisição de imagens descrita na seção 3.3, será realizada na Embrapa-RR que possuía uma equipe de pesquisadores especializados no estudo aprofundado do modo de vida das pragas. Nos primeiros experimentos, uma lupa eletrônica *Leica EZ 4 W* (Figura 4.1(d)), foi usada para tirar as fotos dos insetos. Pela péssima qualidade das fotos, foi projetado uma caixa de forma cubica (50x50x50 cm) pelo qual é colocado no fundo da caixa uma lâmpada *Led Panel Pop* (40x40x4 cm) de 30 W de luminosidade difusa 82 Lm/W e na tampa da caixa, 4 lâmpadas *Spot Led* 12 W de tamanho (17x17x3.6 cm) de luminosidade difusa de 75 Lm/W, todas de cor branca. Em um lateral e na tampa da caixa foi feito uma abertura aonde possamos ter acesso ao inseto para tirar as fotos (Figuras 4.1(b) e 4.1(c)). O equipamento responsável por tirar as fotos são dispositivos móveis como celulares e câmeras fotográficas de uma boa resolução tendo a possibilidade de melhorar o retrato das imagens de insetos ao tirá-las. Inclusive, para obter uma variação nas fotos, é também pensado calcular alguns ângulos aonde será posicionado 2 a 3 espelhos dando uma visão diversas do inseto.

Quanto ao hardware, sobre o qual os experimentos serão feitos, é previsto o uso de computador DELL Inspiron com 16GB de memória RAM de uma placa de vídeo NVIDIA GeForce MX 150 4GB para processamento paralelo em GPU (*Graphics Processing Unit*) no sistema operacional Fedora 30. As ferramentas da plataforma **Anaconda** especializadas para os cientistas de dados serão inclusive instaladas, particularmente O **Jupyter-notebook**. O **Jupyter-notebook** é um ambiente computacional web interativo, além de usar a linguagem python o pesquisador pode organizar trechos de anotações e código de maneira flexível. Os textos e códigos são organizados em células que podem ser inseridas, apagadas, reorganizadas e executadas conforme necessário. As células podem também conter fórmulas matemáticas, plotagens de grafos e imagens. As




Figura 4.1. Ferramenta de Aquisição: (a) Caixa ligada aberta ; (b) Caixa ligada e fechada; (c) Ambiente da caixa; (d) Lupa eletrônica.

diferentes bibliotecas de *Machine Learning* disponíveis na linguagem de programação Python 3.7 serão exploradas de acordo com os resultados parciais obtidos nos experimentos. São elas: *Sklearn-learning*, *Matplotlib*, *Numpy*, *Pandas*, *OpenCv*, *Seaborn*, *H5py*, *Tensorflow-keras*

4.2 Coleta de Dados

Devido à escassez de imagens suficiente sobre o gênero de insetos detectado no estado, nesse trabalho, foi montada uma estrutura para possibilitar aquisição de imagens desses insetos. Os pesquisadores da Embrapa desenvolveram uma técnica de controle que assegura a criação em massa dos insetos. O que possibilita a disposição de vários insetos vivos ou mortos para tirar várias fotos. Devido ao tamanho minúsculo dos insetos, a primeira experiência da aquisição foi elaborada com uma lupa eletrônica (Figura 4.1(d)) conectado ao computador pelo qual, é permitido tirar as fotos pelos programas associados. Entretanto, foi percebido nas fotos tiradas, uma baixa qualidade na nitidez das imagens. Isto é, a lupa apresentava desfoco em partes das imagens quando era possível visualizar com clareza as partes do corpo do inseto. Quanto mais longe fica o foco da lupa nada de palpável é vista.

O equipamento descrito na seção 4.1 será usado, para elaborar vários testes, no intuito de estabelecer um padrão de aquisição das imagens com um fundo de cor branca ou magenta pura. Vale ressaltar como apresentado no capítulo 3 que o processo de coleta de dados é intimamente relacionado a um ciclo de teste entre aquisição, processamento e segmentação da imagem com objetivo de obter uma boa base de dados capaz

proporcionar resultados ótimos na identificação. Isso significa que, quando um conjunto de imagem é adquirido, logo nos efetuaremos automaticamente o pré-processamento e segmentação afim de avaliar a qualidade das imagens tiradas e descartar as imagens de qualidade medíocre, e assim o processo é repetido vários vezes. O algoritmo de processamento será feito usando as bibliotecas de manipulação de imagem, *Numpy* e *OpenCv* que tem como objetivo, remover os ruídos aplicando os filtros e o equalizador de histograma (Seção 3.4 e Figura 3.1). Quanto o algoritmo de segmentação, neste caso, de remoção do fundo será baseada em uma rede neural convolutiva pré-treinada usando a técnica de limiar Ostu Thresholding (Seção 3.5).

4.3 Métricas de Desempenho

A melhor maneira de avaliar a performance de um classificador, de acordo com [Géron \(2017\)](#) no *"Hands-on machine learning with Scikit-Learn and TensorFlow: concepts, tools, and techniques to build intelligent systems."*, é observar a matriz de confusão. A ideia geral da matriz de confusão é de contar o número de vezes, as instâncias da Classe A que são consideradas como a classe B pelo classificador. Por exemplo, para saber o número de vezes que o classificador confundiu as imagens de 5 com 6, basta olhar a primeira linha e a segunda coluna da pseudo matriz de confusão na Figura 4.2. Cada linha da matriz de confusão representa a classe real, enquanto cada coluna representa classe preditiva. A matriz de confusão fornece muitas informações, como (veja uma ilustração na Figura 4.2) :

- Verdadeiro positivo (true positive - TP): significa uma classificação correta da classe positiva. Por exemplo, a classe real é positiva e o modelo classificou como Positivo.
- Falso verdadeiro (true negative - TN): significa uma classificação correta da classe negativa. Por exemplo, a classe real é negativa e o modelo classificou como Negativo.
- Falso positivo (false positive - FP): significa uma classificação errada da classe positiva. Por exemplo, a classe real é negativa e o modelo classificou como Positivo.
- Falso negativo (false negative - FN): significa uma classificação errada da classe negativa. Por exemplo, a classe real é positiva e o modelo classificou como Negativo.

Essas informações possibilitam o cálculo da acurácia sendo uma métrica avaliando:

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (4.1)$$

Mas as métricas como Precision e Recall e F1-score serão também contemplado para avaliar a precisão dos classificadores:

$$Precision = \frac{TP}{TP + FP} \quad (4.2)$$

$$Recall = \frac{TP}{TP + FN} \quad (4.3)$$

$$F_1 = \frac{TP}{TP + \frac{FN + FP}{2}} \quad (4.4)$$




Figura 4.2. Ilustrando a Matriz de Confusão (Géron, 2017)

4.4 Parâmetros Experimentais

A qualidade dos dados para nossos classificadores é até muito louvado, para o sucesso da identificação. Mas alguns parâmetros que até então não foram mencionados, se encontram importante para entendermos como os algoritmos aprendem do conjunto de dados dispostos. Um exemplo palpável, é o *Overfitting*, que é um estado em que os algoritmos aprendem até demais, as características dos dados, (decorar os dados) e percam a sua capacidade de generalização preditiva ao executar novos dados. para corrigir o efeito, uma estratégia pode ser adotada, isto pondo, dados de treinos, de teste

e de validação poderão ser separadas. Um outro problema comum é quando a base de dados se encontra não balanceada, isso afeta também o desempenho do classificador que sempre tende a acertar a classe majoritária. As técnicas de *data augmentation* serão bem uteis para balancear os dados. Alguns algoritmos possuíam parâmetros internos de regularização que operam um controle sobre as taxas de aprendizagem do algoritmo como γ no SVM até mesmo as quantidades de dados (*epoch*) que é aceito por iteração no processo de treinamento. eles são comumente chamados de *Hyper-parâmetros* e possuem um impacto notável nos resultados dos classificadores.

No próximo capítulo, é apresentado o cronograma das atividades para a implementação do projeto.

Capítulo 5

Cronograma

Atividades	Mês								
	Novembro	Dezembro	Janeiro	Fevereiro	Março	Abril	Maiο	Junho	Julho
Fabricação e organização das ferramentas de aquisição de imagens	X								
Aquisição de imagens		X	X						
Realização de Vários Teste de Processamento e de segmentação		X	X						
Definição final da base de dados		X	X						
Estudo das bibliotecas e as ferramentas para implementação do algoritmo				X	X				
Implementação do algoritmo de classificação				X	X				
Treinamento e Teste do modelo preditivo obtido				X	X	X			
Ajuste dos Hyper-parâmetros do modelo preditivo					X	X	X		
Análise e Avaliação da metodologia e os resultados						X	X	X	
Finalização da monografia							X	X	
Apresentação final									X

Tabela 5.1. Cronograma das Atividades.

Referências Bibliográficas

- Andersen, A. N. (1990). The use of and communities to evaluate change in australian terrestrial ecosystems: a review and a recipe. In *Proc. Ecol. Soc. Aust.*, volume 16, pp. 347--357.
- Andrade, C. d. & Valentim, J. (2006). Soluções tecnológicas para a síndrome da morte do capim-marandu. *Morte de pastos de braquiárias. Campo Grande: Embrapa Gado de Corte*, pp. 175--197.
- Arbuckle, T.; Schröder, S.; Steinhage, V. & Wittmann, D. (2001). Biodiversity informatics in action: identification and monitoring of bee species using abis. In *Proc. 15th Int. Symp. Informatics for Environmental Protection*, volume 1, pp. 425--430. ETH Zurich.
- Arce, S. H.; Wu, P.-H. & Tseng, Y. (2013). Fast and accurate automated cell boundary determination for fluorescence microscopy. *Scientific reports*, 3:2266.
- Avci, D. & Varol, A. (2009). An expert diagnosis system for classification of human parasite eggs based on multi-class svm. *Expert Systems with Applications*, 36(1):43-48.
- Bendahan, A. B. (2015). Sistema de integração lavoura-pecuária-floresta (silpf) no estado de roraima, amazônia brasileira. *Embrapa Roraima-Tese/dissertação (ALICE)*.
- Bendahan, A. B. & da Veiga, J. B. (2000). Avaliação das pastagens em propriedades leiteiras da microrregião de castanhal, estado do pará. In *Embrapa Amazônia Oriental-Artigo em anais de congresso (ALICE)*. In: REUNIÃO ANUAL DA SOCIEDADE BRASILEIRA DE ZOOTECNIA, 37., 2000, Viçosa.
- Bengio, Y. et al. (2009). Learning deep architectures for ai. *Foundations and trends® in Machine Learning*, 2(1):1--127.
- Bisgin, H.; Bera, T.; Ding, H.; Semey, H. G.; Wu, L.; Liu, Z.; Barnes, A. E.; Langley, D. A.; Pava-Ripoll, M.; Vyas, H. J. et al. (2018). Comparing svm and ann based

- machine learning methods for species identification of food contaminating beetles. *Scientific reports*, 8(1):6532.
- Bovik, A. C.; Huang, T. S. & Munson, D. C. (1987). The effect of median filtering on edge estimation and detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, (2):181--194.
- Bradbury MH, B. D. (1998). *Introduction to Light Microscopy*. Oxford.
- Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on pattern analysis and machine intelligence*, (6):679--698.
- Castañón, C. A.; Fraga, J. S.; Fernandez, S.; Gruber, A. & Costa, L. d. F. (2007). Biological shape characterization for automatic image recognition and diagnosis of protozoan parasites of the genus eimeria. *Pattern Recognition*, 40(7):1899--1910.
- César, A. D. T.; José, N. M. C.; Elisangela, G. F. & Amaury, B. B. (2019). *Manejo de insetos-praga em pastagens na Amazônia*, capítulo 7, pp. 253--288.
- Cho, J.; Choi, J.; Qiao, M.; Ji, C.-W.; Kim, H.-Y.; UHM, K.-b. & Chon, T. (2008). Automatic identification of tobacco whiteflies, aphids and thrips in greenhouse using image processing techniques. *Red*, 346(246):244.
- Cho, J.; Choi, J.; Qiao, M.; Ji, C.-w.; Kim, H.-y.; Uhm, K.-b. & Chon, T.-s. (2007). Automatic identification of whiteflies, aphids and thrips in greenhouse based on image analysis. *Red*, 346(246):244.
- Cortes, C. & Vapnik, V. (1995). Machine learning. *Support vector networks*, 20(3):25.
- Culverhouse, P. F.; Simpson, R.; Ellis, R.; Lindley, J.; Williams, R.; Parisini, T.; Reguera, B.; Bravo, I.; Zoppoli, R.; Earnshaw, G. et al. (1996). Automatic classification of field-collected dinoflagellates by artificial neural network. *Marine Ecology Progress Series*, 139:281--287.
- Da Silva, R. O. (2019). Fatores determinantes ao ataque do percevejo-das-gramíneas e de lagartas desfolhadoras em pastagens no município de alto alegre, roraima. *Embrapa Roraima-Tese/dissertação (ALICE)*.
- Dias, M. (2011). Os desafios da produção animal em pastagens na fronteira agrícola brasileira. *Revista Brasileira de Zootecnia*, 40:243--252.
- Dias-Filho, M. B. (2007). *Degradação de pastagens: processos, causas e estratégias de recuperação*. Embrapa Amazônia Oriental.

- Dietrich, C. H.; EMIGH, T. H. & DEITZ, L. L. (1991). Morphometric discrimination among females of sibling species of aconophorini (homoptera: Membracidae). *Systematic entomology*, 16(3):311--318.
- Dietrich, C. H. & Pooley, C. D. (1994). Automated identification of leafhoppers (homoptera: Cicadellidae: Draeculacephala ball). *Annals of the Entomological Society of America*, 87(4):412--423.
- Duda, R. O.; Hart, P. E. & Stork, D. G. (2012). *Pattern classification*. John Wiley & Sons.
- Elsayed, K.; Ismail, T. & Ouf, N. (2018). A review on the relevant applications of machine learning in agriculture. *IJIREEICE*, 6:1--17.
- Faithpraise, F.; Birch, P.; Young, R.; Obu, J.; Faithpraise, B. & Chatwin, C. (2013). Automatic plant pest detection and recognition using k-means clustering algorithm and correspondence filters. *International Journal of Advanced Biotechnology and Research*, 4(2):189--199.
- Feng, L.; Bhanu, B. & Heraty, J. (2016). A software system for automated identification and retrieval of moth images based on wing attributes. *Pattern Recognition*, 51:225--241.
- Flusser, J. & Suk, T. (1993). Pattern recognition by affine moment invariants. *Pattern recognition*, 26(1):167--174.
- Francoy, T. M.; Wittmann, D.; Drauschke, M.; Müller, S.; Steinhage, V.; Bezerra-Laure, M. A.; De Jong, D. & Gonçalves, L. S. (2008). Identification of africanized honey bees through wing morphometrics: two fast and efficient procedures. *Apidologie*, 39(5):488--494.
- Gauld, I.; O'Neill, M.; Gaston, K. et al. (2000). Driving miss daisy: the performance of an automated insect identification system. *Hymenoptera: evolution, biodiversity and biological control*, pp. 303--312.
- Géron, A. (2017). *Hands-on machine learning with Scikit-Learn and TensorFlow: concepts, tools, and techniques to build intelligent systems*. "O'Reilly Media, Inc."
- Gonzalez RC, W. R. (2007). *Digital Image Processing*. 3ed edição.
- Hammond, P. (1992). Species inventory. *G. B (Ed.), Global biodiversity, Chapman and Hall, London*, p. 17?39.

- Hanqing, Z.; Zuorui, S. & Xinwen, Y. (2002). On computer-aided insect identification through math-morphology features. *Zhonggou Nongye Daxue Xuebao (China)*.
- Haralick RM, S. L. (1992). *Computer and Robot Vision*. Boston, MA, USA.
- Hernández-Serna, A. & Jiménez-Segura, L. F. (2014). Automatic identification of species with neural networks. *PeerJ*, 2:e563.
- Hu, M.-K. (1962). Visual pattern recognition by moment invariants. *IRE transactions on information theory*, 8(2):179--187.
- Huddar, S. R.; Gowri, S.; Keerthana, K.; Vasanthi, S. & Rupanagudi, S. R. (2012). Novel algorithm for segmentation and automatic identification of pests on plants using image processing. In *2012 Third International Conference on Computing, Communication and Networking Technologies (ICCCNT'12)*, pp. 1--5.
- Islam, M. M.; Zhang, D. & Lu, G. (2008). A geometric method to compute directionality features for texture images. In *2008 IEEE International Conference on Multimedia and Expo*, pp. 1521--1524. IEEE.
- Jain, A. K.; Duin, R. P. W. & Mao, J. (2000). Statistical pattern recognition: A review. *IEEE Transactions on pattern analysis and machine intelligence*, 22(1):4--37.
- Jonas, B.D.A.V ; Italo, C. (1986). Recomendação e prática de adubação de pastagens cultivadas na amazônia brasileira. *MATTOS, H. B.; WERNER, J. C.; YAMADA, T.; MALAVOLTA, E. (Ed.). Calagem e adubação de pastagens. Piracicaba: POTAFOS, 1986.*, pp. p. 256--282.
- Kalafi, E. Y.; Town, C. & Dhillon, S. K. (2018). How automated image analysis techniques help scientists in species identification and classification? *Folia morphologica*, 77(2):179--193.
- Kang, W.-X.; Yang, Q.-Q. & Liang, R.-P. (2009). The comparative research on image segmentation algorithms. In *2009 First International Workshop on Education Technology and Computer Science*, volume 2, pp. 703--707. IEEE.
- Kaya, Y.; Kayci, L. & Uyar, M. (2015). Automatic identification of butterfly species based on local binary patterns and artificial neural network. *Applied Soft Computing*, 28:132--137.
- Khan, W. (2013). Image segmentation techniques: A survey. *Journal of Image and Graphics*, 1(4):166--170.

- Kimberling, D. N.; Karr, J. R. & Fore, L. S. (2001). Measuring human disturbance using terrestrial invertebrates in the shrub-steppe of eastern washington (usa). *Ecological indicators*, 1(2):63--81.
- Kiranyaz, S.; Ince, T.; Pulkkinen, J.; Gabbouj, M.; Ärje, J.; Kärkkäinen, S.; Tirronen, V.; Juhola, M.; Turpeinen, T. & Meissner, K. (2011). Classification and retrieval on macroinvertebrate image databases. *Computers in biology and medicine*, 41(7):463-472.
- Kremen, C. (1992). Assessing the indicator properties of species assemblages for natural areas monitoring. *Ecological applications*, 2(2):203--217.
- Larios, N.; Deng, H.; Zhang, W.; Sarpola, M.; Yuen, J.; Paasch, R.; Moldenke, A.; Lytle, D. A.; Correa, S. R.; Mortensen, E. N. et al. (2008). Automated insect identification through concatenated histograms of local appearance features: feature vector generation and region detection for deformable objects. *Machine Vision and Applications*, 19(2):105--123.
- Lawton, J. H.; Bignell, D.; Bolton, B.; Bloemers, G.; Eggleton, P.; Hammond, P.; Hodda, M.; Holt, R.; Larsen, T.; Mawdsley, N. et al. (1998). Biodiversity inventories, indicator taxa and effects of habitat modification in tropical forest. *Nature*, 391(6662):72.
- LeCun, Y.; Bengio, Y. & Hinton, G. (2015). Deep learning. *nature* 521.
- Leow, L. K.; Chew, L.-L.; Chong, V. C. & Dhillon, S. K. (2015). Automated identification of copepods using digital image processing and artificial neural network. *BMC bioinformatics*, 16(18):S4.
- Liu, F.; Shen, Z.; Zhang, J. & Yang, H. (2008). Automatic insect identification based on color characters. *Chinese Bulletin of Entomology*, 45(1):150--153.
- Loncaric, S. (1998). A survey of shape analysis techniques. *Pattern recognition*, 31(8):983--1001.
- Martin, V.; Moisan, S.; Paris, B. & Nicolas, O. (2008). O. 50-towards a video camera network for early pest detection in greenhouses. In *ENDURE International Conference*, pp. 1--5.
- Martineau, M.; Conte, D.; Raveaux, R.; Arnault, I.; Munier, D. & Venturini, G. (2017). A survey on image-based insect classification. *Pattern Recognition*, 65:273--284.

- Mayo, M. & Watson, A. T. (2007). Automatic species identification of live moths. *Knowledge-Based Systems*, 20(2):195--202.
- Mutwiwa, U. N. & Tantau, H. J. (2005). Suitability of a uv lamp for trapping the greenhouse whitefly *Trialeurodes vaporariorum* Westwood (Hom: Aleyrodidae). *Agricultural Engineering International: CIGR Journal*.
- Mythili, C. & Kavitha, V. (2011). Efficient technique for color image noise reduction. *The research bulletin of Jordan, ACM*, 1(11):41--44.
- Ødegaard, F. (2000). How many species of arthropods? Erwin's estimate revised. *Biological Journal of the Linnean Society*, 71(4):583--597.
- Ojala, T.; Pietikäinen, M. & Mäenpää, T. (2002). Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis & Machine Intelligence*, (7):971--987.
- O'Neill, M.; Gauld, I.; Gaston, K. & Weeks, P. (2000). Daisy: an automated invertebrate identification system using holistic vision techniques. In *Proceedings of the Inaugural Meeting BioNET-INTERNATIONAL Group for Computer-Aided Taxonomy (BIGCAT)*, pp. 13--22.
- O'Neill, M. A. (2000). Daisy: a practical tool for semi-automated species identification. *Automated taxon identification in systematics: theory, approaches, and applications*. CRC Press/Taylor & Francis Group, Boca Raton/Florida, pp. 101--114.
- Parisi-Baradad, V.; Manjabacas, A.; Lombarte, A.; Olivella, R.; Chic, Ò.; Piera, J. & García-Ladona, E. (2010). Automated taxon identification of teleost fishes using an otolith online database? *Fisheries Research*, 105(1):13--20.
- Picon, A.; Alvarez-Gila, A.; Seitz, M.; Ortiz-Barredo, A.; Echazarra, J. & Johannes, A. (2018). Deep convolutional neural networks for mobile capture device-based crop disease classification in the wild. *Computers and Electronics in Agriculture*.
- Ping Tian, D. et al. (2013). A review on image feature extraction and representation techniques. *International Journal of Multimedia and Ubiquitous Engineering*, 8(4):385--396.
- Rokach, L. (2010). Ensemble-based classifiers. *Artificial Intelligence Review*, 33(1-2):1--39.

- Rother, C.; Kolmogorov, V. & Blake, A. (2004). Grabcut: Interactive foreground extraction using iterated graph cuts. In *ACM transactions on graphics (TOG)*, volume 23, pp. 309--314. ACM.
- Santhi, N.; Pradeepa, C.; Subashini, P. & Kalaiselvi, S. (2013). Automatic identification of algal community from microscopic images. *Bioinformatics and biology insights*, 7:BBI--S12844.
- Saraswat, M. & Arya, K. (2014). Automated microscopic image analysis for leukocytes identification: A survey. *Micron*, 65:20--33.
- Savkare, S.; Narote, S. et al. (2011). Automatic detection of malaria parasites for estimating parasitemia. *International Journal of Computer Science and Security (IJCSS)*, 5(3):310.
- Schmidhuber, J. (2015). Deep learning in neural networks: An overview. *Neural networks*, 61:85--117.
- Schröder, S.; Drescher, W.; Steinhage, V. & Kastenholz, B. (1995). An automated method for the identification of bee species (hymenoptera: Apoidea). In *Proc. Intern. Symp. on Conserving Europe's Bees. Int. Bee Research Ass. & Linnean Society, London*, pp. 6--7.
- Shih, T. K.; Huang, J.-Y.; Wang, C.-S.; Hung, J. C. & Kao, C.-H. (2001). An intelligent content-based image retrieval system based on color, shape and spatial relations. *proceedings-national science council republic of China part a physical science and engineering*, 25(4):232--243.
- Simon, J.; de Moraes, E.; Bendahan, A. & SCHURT, D. (2017). Ocorrência de percevejos-das-gramíneas (*blissus* sp.) em braquirão e mombaça no município de alto alegre-roraima. In *Embrapa Roraima-Resumo em anais de congresso (ALICE)*. In: SEMANA NACIONAL DE CIÊNCIA E TECNOLOGIA NO ESTADO DE RORAIMA, 11., 2016 ?
- Simonyan, K. & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*.
- Singh, H. K.; Tomar, S. K. & Maurya, P. K. (2012). Thresholding techniques applied for segmentation of rgb and multispectral images. *Proceedings published by International Journal of Computer Applications®(IJCA) ISSN*, pp. 0975--8887.

- Solis-Sánchez, L.; García-Escalante, J.; Castañeda-Miranda, R.; Torres-Pacheco, I. & Guevara-González, R. (2009). Machine vision algorithm for whiteflies (*bemisia tabaci* genn.) scouting under greenhouse environment. *Journal of applied entomology*, 133(7):546--552.
- Steinhage, V.; Schroder, S.; Lampe, K. & Cremers, A. (2007). Chapter 8 automated extraction and analysis of morphological features for species identification. *SYSTEMATICS ASSOCIATION SPECIAL VOLUME*, 74:115.
- Teixeira, C. A. D.; Costa, J. N. M. (2016). *Pragas Agrícolas e florestais na Amazônia 1.*, capítulo Pastagens, pp. 393--417. Brasília: Embrapa.
- Tofilski, A. (2004). Drawwing, a program for numerical description of insect wings. *Journal of Insect Science*, 4(1).
- Tofilski, A. (2007). Automatic measurement of honeybee wings. In MacLeod, N., editor, *Automated taxon identification in systematics: theory, approaches and applications*. Boca Raton, Florida: CRC Press., pp. 277--288.
- Trattner, S.; Greenspan, H.; Tepper, G. & Abboud, S. (2004). Automatic identification of bacterial types using statistical imaging methods. *IEEE transactions on medical imaging*, 23(7):807--820.
- Valan, M.; Makonyi, K.; Maki, A.; Vondrá?ek, D. & Ronquist, F. (2019). Automated Taxonomic Identification of Insects with Expert-Level Accuracy Using Effective Feature Transfer from Convolutional Networks. *Systematic Biology*. syz014.
- VALERIO, J.; REIS, P. et al. (2015). Percevejo-das-gramíneas, blissus? leucopterus. *Embrapa Gado de Corte-Capítulo em livro científico (ALICE)*.
- Wang, J.; Lin, C.; Ji, L. & Liang, A. (2012). A new automatic identification system of insect images at the order level. *Knowledge-Based Systems*, 33:102--110.
- Watson, A. T.; O'Neill, M. A. & Kitching, I. J. (2004). Automated identification of live moths (macrolepidoptera) using digital automated identification system (daisy). *Systematics and Biodiversity*, 1(3):287--300.
- Weeks, P.; Gauld, I.; Gaston, K. & O'Neill, M. (1997). Automating the identification of insects: a new solution to an old problem. *Bulletin of Entomological Research*, 87(2):203--211.

- Weeks, P.; O'Neill, M.; Gaston, K. & Gauld, I. (1999a). Automating insect identification: exploring the limitations of a prototype system. *Journal of Applied Entomology*, 123(1):1--8.
- Weeks, P.; O'Neill, M. A.; Gaston, K. & Gauld, I. (1999b). Species-identification of wasps using principal component associative memories. *Image and Vision Computing*, 17(12):861--866.
- Wen, C. & Guyer, D. (2012). Image-based orchard insect automated identification and classification method. *Computers and Electronics in Agriculture*, 89:110--115.
- Wen, C.; Wu, D.; Hu, H. & Pan, W. (2015). Pose estimation-dependent identification method for field moth images using deep learning architecture. *biosystems engineering*, 136:117--128.
- Yang, H.-P.; Ma, C.-S.; Wen, H.; Zhan, Q.-B. & Wang, X.-L. (2015). A tool for developing an automatic insect identification system based on wing outlines. *Scientific reports*, 5:12786.
- Yang, M.; Kpalma, K. & Ronsin, J. (2008). A survey of shape feature extraction techniques.
- Zhang, D. & Lu, G. (2004). Review of shape representation and description techniques. *Pattern recognition*, 37(1):1--19.
- Zhang, Z.-Q. (2011). *Animal biodiversity: An outline of higher-level classification and survey of taxonomic richness*. Magnolia press.
- Zhu, L.-Q. & Zhang, Z. (2010). Auto-classification of insect images based on color histogram and glcm. In *2010 Seventh International Conference on Fuzzy Systems and Knowledge Discovery*, volume 6, pp. 2589--2593. IEEE.
- Zhu, L.-q. & Zhang, Z. (2011). Insect recognition based on integrated region matching and dual tree complex wavelet transform. *Journal of Zhejiang University SCIENCE C*, 12(1):44--53.